

Where are they looking?

Temas de Investigación I


Arotoma Bacilio, Bitzer Nazareth
Bedon Vasquez, Bruno Fabio
Huarcaya Canal, Oscar
Mejia Puma, Miguel Angel

Universidad Nacional de Ingeniería
Facultad de Ciencias

Escuela Profesional de Ciencia de la Computación



Detalles del Trabajo



El desarrollo del presente trabajo incluye:

1. Estructuración de los datos.
2. Preparación de los modelos.
3. Evaluación de modelos.
4. Validación de resultados.
5. Análisis y Conclusiones.

Where are they looking

Team Bomb!

1 Introducción

Porqué localización de interiores

Porqué Machine Learning

Definición del Problema

Indoor Location

Casos de Prueba

Modelos de Aprendizaje

Accuracy y Error Medio

Resultados

Caso 1

Caso 2

Caso 3

Conclusiones

Introducción

Porqué localización de interiores



Las aplicaciones más frecuentes son:

- Marketing en retail (*publicidad, oferta, cupones*).
- Orientación en interiores (*guías*).
- Eficiencia en la atención (*grado de incidencia*).



Where are they looking

Team Bomb!

2

Introducción

Porqué localización de interiores

Porqué Machine Learning

Definición del Problema

Indoor Location

Casos de Prueba

Modelos de Aprendizaje

Accuracy y Error Medio

Resultados

Caso 1

Caso 2

Caso 3

Conclusiones

Soluciones para indoor location



Ecuación de Rappaport:

$$RSSI = -10n\log(d) + txPower$$

Propuesta:

Modelar usando Machine Learning.

Where are they looking

Team Bomb!

Introducción

Porqué localización de interiores

3 Porqué Machine Learning

Definición del Problema

Indoor Location

Casos de Prueba

Modelos de Aprendizaje

Accuracy y Error Medio

Resultados

Caso 1

Caso 2

Caso 3


Conclusiones

Introducción

Definición del Problema



Area Experimental



Where are they looking

Team Bomb!

Introducción

Porqué localización de interiores

Porqué Machine Learning

4

Definición del Problema

Indoor Location

Casos de Prueba

Modelos de Aprendizaje

Accuracy y Error Medio

Resultados

Caso 1

Caso 2

Caso 3

Conclusiones



Casos de Prueba

El presente trabajo evalúa la eficiencia para tres tipos de sucesos.

- ▶ Caso 1:
Emisor: Microcontroller BLE 4.0, a un único nivel de potencia.
Receptor: Raspberry Pi con antena BLE 4.0.
- ▶ Caso 2:
Emisor: Beacon BLE 4.0, a siete niveles de potencia.
Receptor: Raspberry Pi con antena BLE 4.0.
- ▶ Caso 3:
Emisor: Beacon BLE 4.0, a siete niveles de potencia.
Receptor: Smartphone BLE 4.0.

Where are they looking

Team Bomb!

Introducción

Porqué localización de interiores

Porqué Machine Learning

Definición del Problema

5

Indoor Location

Casos de Prueba

Modelos de Aprendizaje

Accuracy y Error Medio

Resultados

Caso 1

Caso 2

Caso 3


Conclusiones

Indoor Location

Casos de Prueba



Caso 1: microController → RPI2



Where are they looking

Team Bomb!

Introducción

Porqué localización de interiores

Porqué Machine Learning

Definición del Problema

Indoor Location

6

Casos de Prueba

Modelos de Aprendizaje

Accuracy y Error Medio

Resultados

Caso 1

Caso 2

Caso 3

Conclusiones

Caso 2: Beacon → RPI2

Where are they looking

Team Bomb!

Introducción

Porqué localización de interiores
Porqué Machine Learning
Definición del Problema

Indoor Location

Casos de Prueba

Modelos de Aprendizaje
Accuracy y Error Medio

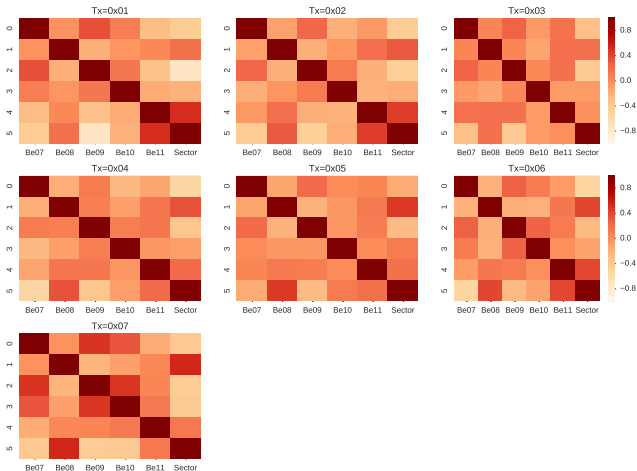
Resultados

Caso 1
Caso 2
Caso 3

Conclusiones

7

22



Caso 3: Beacon → Smartphone

Where are they looking

Team Bomb!

Introducción

Porqué localización de interiores
Porqué Machine Learning
Definición del Problema

Indoor Location

8


Casos de Prueba

Modelos de Aprendizaje
Accuracy y Error Medio

Resultados

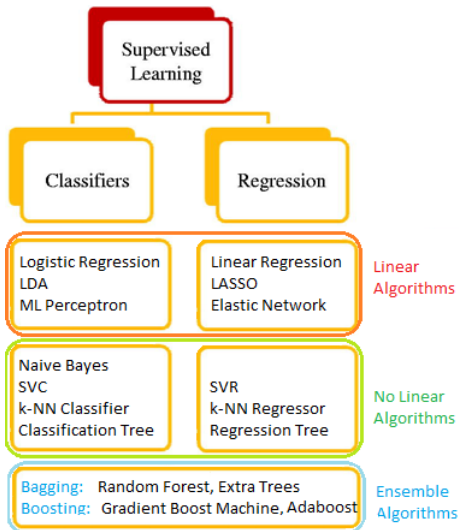
Caso 1
Caso 2
Caso 3

Conclusiones



Indoor Location

Modelos de Aprendizaje



Where are they looking

Team Bomb!

Introducción

Porqué localización de interiores

Porqué Machine Learning

Definición del Problema

Indoor Location

Casos de Prueba

Modelos de Aprendizaje

Accuracy y Error Medio

Resultados

Caso 1

Caso 2

Caso 3

Conclusiones


9

22

Precisión

$$Precision = nAciertos / nTest \times 100\%$$

Error Métrico



$$dv = | p/3 - y/3 | \times 1.5 - 1.0$$

$$dh = | p\%3 - y\%3 | \times 1.5 - 1.0$$

$$d = \sqrt{dv^2 + dh^2}$$

Where are they looking

Team Bomb!

Introducción

Porqué localización de interiores

Porqué Machine Learning

Definición del Problema

Indoor Location

Casos de Prueba

Modelos de Aprendizaje

Accuracy y Error Medio

10

Resultados

Caso 1

Caso 2

Caso 3

Conclusiones


22

Resultados

Caso 1: microController → RPI2



Evaluación de Clasificación



Where are they looking

Team Bomb!

Introducción

Porqué localización de interiores
Porqué Machine Learning
Definición del Problema

Indoor Location

Casos de Prueba
Modelos de Aprendizaje
Accuracy y Error Medio

Resultados

- 11 Caso 1
- Caso 2
- Caso 3


Conclusiones

Resultados

Caso 1: microController → RPI2



Evaluación de Regresión



Where are they looking

Team Bomb!

Introducción

Porqué localización de interiores

Porqué Machine Learning

Definición del Problema

Indoor Location

Casos de Prueba

Modelos de Aprendizaje

Accuracy y Error Medio

Resultados

12

Caso 1

Caso 2

Caso 3

Conclusiones

Resultados

Caso 1: microController → RPI2



Clasificación

Modelo	Precisión (%)	Error Medio (m)
LoR	49.90	0.53
MLP	67.44	0.32
LDA	49.82	0.51
KNN	82.50	0.19
CART	80.95	0.20
NB	65.85	0.36
SVM	80.38	0.20
AB	86.33	0.15
GBM	88.05	0.13
RF	87.07	0.14
ET	87.19	0.14

Regresión

Modelo	Precisión (%)	Error Medio (m)
LiR	7.47	0.65
Lasso	7.14	0.65
EN	7.14	0.65
KNN	52.67	0.32
CART	52.06	0.36
SVR	43.29	0.41
AB	58.02	0.27
GBM	45.65	0.37
RF	53.57	0.31
ET	54.14	0.30

Where are they looking

Team Bomb!

Introducción

Porqué localización de interiores

Porqué Machine Learning

Definición del Problema

Indoor Location

Casos de Prueba

Modelos de Aprendizaje

Accuracy y Error Medio

Resultados

Caso 1

Caso 2

Caso 3

Conclusiones

13

22

Resultados

Caso 2: Beacon → RPI2



Evaluación de Clasificación



Where are they looking

Team Bomb!

Introducción

Porqué localización de interiores

Porqué Machine Learning

Definición del Problema

Indoor Location

Casos de Prueba

Modelos de Aprendizaje

Accuracy y Error Medio

Resultados

Caso 1

Caso 2

Caso 3

Conclusiones

14

22

Resultados

Caso 2: Beacon → RPI2



Resultados de Precisión y Error por Clasificación

Modelo	Tx=0x01	0x02	0x03	0x04	0x05	0x06	0x07
LoR	60.29	47.24	51.66	57.28	50.07	62.35	83.93
MLP	68.22	67.55	64.93	68.29	67.38	72.17	82.79
LDA	57.09	45.37	49.70	56.59	47.71	58.71	75.02
KNN	78.98	80.90	83.03	81.95	78.55	86.83	90.92
CART	75.71	76.38	80.32	78.82	72.19	87.05	90.13
NB	66.76	63.46	70.06	69.97	62.50	72.84	88.12
SVM	74.55	75.09	81.37	79.51	74.70	85.19	90.31
AB	81.67	81.91	85.97	82.93	79.44	89.66	92.93
GBM	84.44	85.43	87.71	87.60	83.73	91.52	93.97
RF	81.60	84.21	86.05	84.88	81.14	90.25	92.66
ET	82.47	83.13	86.95	85.71	80.92	90.25	92.49

Modelo	Tx=0x01	0x02	0x03	0x04	0x05	0x06	0x07
LoR	0.32	0.49	0.49	0.35	0.52	0.32	0.15
MLP	0.26	0.28	0.35	0.29	0.34	0.26	0.16
LDA	0.34	0.5	0.51	0.36	0.53	0.36	0.23
KNN	0.17	0.17	0.18	0.15	0.23	0.12	0.09
CART	0.21	0.21	0.22	0.18	0.29	0.13	0.1
NB	0.26	0.32	0.32	0.26	0.38	0.24	0.11
SVM	0.21	0.24	0.19	0.19	0.28	0.14	0.09
AB	0.16	0.16	0.15	0.14	0.21	0.1	0.07
GBM	0.13	0.13	0.13	0.1	0.17	0.08	0.06
RF	0.16	0.13	0.16	0.12	0.19	0.1	0.07
ET	0.15	0.15	0.14	0.11	0.21	0.09	0.07

Where are they looking

Team Bomb!

Introducción

Porqué localización de interiores

Porqué Machine Learning

Definición del Problema

Indoor Location

Casos de Prueba

Modelos de Aprendizaje

Accuracy y Error Medio

Resultados

Caso 1

Caso 2

Caso 3

Conclusiones

15


22

Resultados

Caso 2: Beacon → RPI2



Evaluación de Regresión



Where are they looking

Team Bomb!

Introducción

Porqué localización de interiores

Porqué Machine Learning

Definición del Problema

Indoor Location

Casos de Prueba

Modelos de Aprendizaje

Accuracy y Error Medio

Resultados

Caso 1

Caso 2

Caso 3

Conclusiones

16

22

Resultados

Caso 2: Beacon → RPI2



Resultados de Precisión y Error por Regresión

Modelo	Tx=0x01	0x02	0x03	0x04	0x05	0x06	0x07
LiR	18.18	14.43	14.40	15.54	10.36	15.48	20.52
Lasso	18.76	15.00	13.12	15.54	10.28	14.58	20.79
EN	17.75	14.86	13.05	15.40	10.21	14.66	21.31
KNN	47.78	48.03	48.94	54.22	42.90	54.39	59.65
CART	46.18	46.09	48.04	51.36	41.64	54.61	60.09
SVR	33.09	36.68	39.67	43.90	36.17	47.84	55.46
AB	52.36	52.05	54.37	57.28	49.19	59.08	61.14
GBM	45.09	44.44	43.51	48.36	37.87	49.26	55.37
RF	49.82	48.89	51.81	55.05	43.05	55.73	58.08
ET	50.40	49.46	51.13	54.15	41.72	55.36	59.21

Modelo	Tx=0x01	0x02	0x03	0x04	0x05	0x06	0x07
LiR	0.53	0.60	0.66	0.60	0.68	0.62	0.52
Lasso	0.53	0.60	0.66	0.60	0.68	0.62	0.52
EN	0.53	0.60	0.66	0.60	0.68	0.62	0.52
KNN	0.31	0.30	0.32	0.28	0.36	0.28	0.24
CART	0.35	0.35	0.36	0.33	0.43	0.30	0.25
SVR	0.43	0.41	0.40	0.39	0.45	0.35	0.28
AB	0.28	0.28	0.28	0.26	0.32	0.25	0.22
GBM	0.34	0.35	0.38	0.34	0.41	0.33	0.27
RF	0.29	0.30	0.31	0.28	0.36	0.28	0.24
ET	0.29	0.30	0.31	0.28	0.36	0.28	0.24

Where are they looking

Team Bomb!

Introducción

Porqué localización de interiores

Porqué Machine Learning

Definición del Problema

Indoor Location

Casos de Prueba

Modelos de Aprendizaje

Accuracy y Error Medio

Resultados

Caso 1

Caso 2

Caso 3

Conclusiones

17


22

Resultados

Caso 3: Beacon → Smartphone



Evaluación de Clasificación



Where are they looking

Team Bomb!

Introducción

Porqué localización de interiores

Porqué Machine Learning

Definición del Problema

Indoor Location

Casos de Prueba

Modelos de Aprendizaje

Accuracy y Error Medio

Resultados

Caso 1

Caso 2

Caso 3

Conclusiones

18

22

Resultados

Caso 3: Beacon → Smartphone



Resultados de Precisión y Error por Clasificación

Modelo	Tx=0x01	0x02	0x03	0x04	0x05	0x06	0x07
LoR	10.01	9.64	8.19	8.7	11.09	10.65	14.73
MLP	7.55	6.65	6.99	7.14	7.51	9.09	13.28
LDA	10.01	9.64	8.19	8.77	11.06	10.97	14.73
KNN	9.35	9.56	11.41	9.18	8.42	8.37	9.71
CART	13.83	13.25	13.26	13.71	13.25	11.89	15.4
NB	11.26	10.16	10.07	9.69	12.71	11.61	14.51
SVM	13.83	13.20	13.34	13.71	13.25	11.81	15.63
AB	13.83	13.15	13.31	13.74	13.25	11.89	15.29
GBM	13.64	13.61	13.60	13.68	13.22	11.89	15.96
RF	13.69	13.69	13.10	13.48	13.31	12.29	15.29
ET	13.83	13.25	13.26	13.71	13.25	11.89	15.4

Modelo	Tx=0x01	0x02	0x03	0x04	0x05	0x06	0x07
LoR	1.04	1.07	1.1	0.98	0.95	1.00	0.78
MLP	1.22	0.91	1.36	0.93	0.90	0.86	0.78
LDA	1.03	1.07	1.1	0.99	0.95	0.97	0.78
KNN	1.01	1.04	1.01	1.01	1.06	1.07	0.97
CART	0.88	0.89	0.95	0.97	0.90	0.91	0.82
NB	0.94	1.00	0.94	1.11	0.90	0.89	0.79
SVM	0.88	0.88	0.96	0.96	0.90	0.91	0.81
AB	0.88	0.89	0.96	0.96	0.90	0.91	0.81
GBM	0.88	0.89	0.95	0.97	0.90	0.91	0.80
RF	0.87	0.89	0.94	0.97	0.91	0.90	0.82
ET	0.88	0.89	0.95	0.97	0.90	0.91	0.82

Where are they looking

Team Bomb!

Introducción

Porqué localización de interiores

Porqué Machine Learning

Definición del Problema

Indoor Location

Casos de Prueba

Modelos de Aprendizaje

Accuracy y Error Medio

Resultados

Caso 1

Caso 2

Caso 3

Conclusiones

19


22

Resultados

Caso 3: Beacon → Smartphone



Evaluación de Regresión



Where are they looking

Team Bomb!

Introducción

Porqué localización de interiores

Porqué Machine Learning

Definición del Problema

Indoor Location

Casos de Prueba

Modelos de Aprendizaje

Accuracy y Error Medio

Resultados

Caso 1

Caso 2

Caso 3

20

Conclusiones

22

Resultados

Caso 3: Beacon → Smartphone



Resultados de Precisión y Error por Regresión

Modelo	Tx=0x01	0x02	0x03	0x04	0x05	0x06	0x07
LiR	7.04	6.55	6.13	5.77	8.57	9.09	11.05
Lasso	7.04	6.55	6.13	5.77	8.57	9.09	11.05
EN	7.04	6.55	6.13	5.77	8.57	9.09	11.05
KNN	7.12	7.79	8.33	7.17	6.69	7.13	10.16
CART	7.69	7.92	8.09	5.83	8.57	9.21	11.94
SVR	7.72	9.12	8.01	7.59	9.15	9.49	12.05
AB	7.69	7.82	7.61	5.83	8.60	9.13	11.83
GBM	7.69	7.92	8.09	5.80	8.57	9.21	11.94
RF	7.55	7.87	8.09	6.38	8.60	9.21	11.94
ET	7.69	7.92	8.09	5.83	8.57	9.21	11.94

Modelo	Tx=0x01	0x02	0x03	0x04	0x05	0x06	0x07
LiR	0.76	0.78	0.78	0.77	0.76	0.75	0.67
Lasso	0.76	0.78	0.78	0.77	0.76	0.75	0.67
EN	0.76	0.78	0.78	0.77	0.76	0.75	0.67
KNN	0.81	0.79	0.83	0.79	0.82	0.80	0.73
CART	0.75	0.75	0.75	0.75	0.75	0.74	0.66
SVR	0.75	0.75	0.75	0.75	0.75	0.75	0.66
AB	0.75	0.76	0.76	0.75	0.75	0.74	0.66
GBM	0.75	0.75	0.75	0.75	0.75	0.74	0.66
RF	0.75	0.75	0.75	0.75	0.75	0.74	0.66
ET	0.75	0.75	0.75	0.75	0.75	0.74	0.66

Where are they looking

Team Bomb!

Introducción

Porqué localización de interiores

Porqué Machine Learning

Definición del Problema

Indoor Location

Casos de Prueba

Modelos de Aprendizaje

Accuracy y Error Medio

Resultados

Caso 1

Caso 2

Caso 3

Conclusiones

21

22

Conclusiones



- ▶ A menor nivel de potencia, mayor precisión.
- ▶ El caso 3 presenta muy bajo rendimiento, debido a que los cinco sensores colocados son linealmente dependientes.
- ▶ El caso 2 tiene la más alta precisión, llegando hasta un 93.97%, muy recomendable para ambientes reducidos y de mayor afinamiento.
- ▶ Los algoritmos lineales en clasificación tienen menor precisión.
- ▶ Los algoritmos de conjunto tienen mayor precisión.
- ▶ Los algoritmos de clasificación tienen mayor representatividad.
- ▶ El error métrico promedio varía desde 0.06m hasta 1.5m a partir del extremo del sector.

Where are they looking

Team Bomb!

Introducción

Porqué localización de interiores

Porqué Machine Learning

Definición del Problema

Indoor Location

Casos de Prueba

Modelos de Aprendizaje

Accuracy y Error Medio

Resultados

Caso 1

Caso 2

Caso 3

22

Conclusions

Gracias por su atención

